

Tipología y Ciclo de vida de los datos: Web Scraping

Ismael Rosende Rey y Chantal López Procopio

Noviembre, 2020

1 Contexto

En el presente proyecto, hemos creado un web crawler capaz de navegar por la web del supermercado Carrefour, extrayendo los datos de los diferentes productos que allí se exponen y sus atributos principales (precios, ofertas y promociones). Este ejercicio tiene como finalidad entender y poner en práctica los conceptos aprendidos en la asignatura de Tipología y Ciclo de Vida de los Datos, asignatura perteneciente al Máster en Ciencia de los Datos de la Universitat Oberta de Catalunya, para realizar un Web Scraping.

2 Título Dataset

El título escogido para este dataset es CarrefourDailyPricing, ya que guarda relación directa con el propósito de la araña que hemos creado para este proyecto, ella se explica detalladamente a continuación.

3 Descripción del Dataset

El dataset CarrefourDailyPricing está formado por una lista con los productos del supermercado Carrefour, guardando los datos más importantes como: la categoría del producto, su precio actual, precio por medida, ofertas y promociones, entre otros.

4 Gráfica



Figure 1: Imagen ilustrativa del dataset

5 Contenido del dataset

El dataset CarrefourDailyPricing contiene los siguientes atributos:

- Sección: Sección del supermercado a la que pertenece un producto.
- Categoría: Categoría dentro de la sección a la que pertenece un producto.
- Descripción: Nombre que tiene asociado el producto en el supermercado.
- Precio: Precio de venta actual.
- PrecioMedida: Precio por cada unidad de medida (Kg, g, L, ml, lavados, ud).
- PrecioPrevio: Precio de venta anterior a la oferta.
- PrecioOferta: Precio de venta durante la oferta.
- Promoción: Promoción activa del producto.
- Enlace: Enlace donde se puede encontrar el producto en cuestión.

La araña está programada para actualizar el dataset una vez al día, a las 8:00hrs, generando un csv nuevo con los atributos ya mencionados.

6 Agradecimientos

Para elaborar este proyecto, recurrimos a la web de Carrefour para extraer datos de los productos que el supermercado ofrece dentro de su oferta comercial. Agradecemos por su aporte a este proyecto como nuestra fuente principal de datos, pero también haber sido de gran ayuda durante nuestra formación y aprendizaje.

7 Inspiración

Este conjunto de datos busca recoger diariamente información de interés sobre cada producto en el supermercado Carrefour. Durante la elaboración de este proyecto, no solo buscamos la extracción de datos, sino también poder llevar un registro donde comparar las subidas y bajadas de precios en un período de tiempo determinado. Por esa razón, hemos programado la araña para que recorra la web diariamente, y así poder remarcar los productos en oferta, cada cuánto tiempo ocurren y su evolución en el tiempo. También, serviría para estudiar el impacto que tienen sobre la economía las crisis como la que vivimos actualmente del covid.

8 Licencia

El dataset CarrefourDailyPricing tendrá una licencia del tipo Attribution-NonCommercial-ShareAlike 4.0. Lo que implica que las personas son libres de utilizar el dataset como prefieran, pero sin obtener una retribución de tipo comercial. La creación del dataset fue hecho meramente con fines educativos, por lo que nuestro principal interés recae en que otras personas puedan aprender de él, modificarlo a gusto y ampliar su contenido como les parezca conveniente dentro de estos parámetros.

9 Código del Dataset

El código fuente y el dataset generado con nuestra araña “carrefourSpider”, se pueden encontrar en el siguiente enlace: <https://github.com/equipoUOC/CarrefourTracker>

10 Contribuciones

Contribuciones	Firma
Investigación previa	IRR, CLP
Redacción de las respuestas	IRR, CLP
Desarrollo código	IRR, CLP

11 Recursos

- Subirats, L., Calvo, M. (2018). Web Scraping. Editorial UOC.
- SLawson, R. (2015). Web Scraping with Python. Packt Publishing Ltd. Chapter 2.Scraping the Data.